噪声该加在哪儿

协变混淆里「先加噪再混淆」与「先混淆再加噪」之辨

fastProve 项目内部技术说明

2026 年 9 月 19 日

这份文档回答什么

我们的协变混淆已经做了「升维」。现在的问题是：到底应该*先*做 LWE 式的增广矩阵加噪、*再*做混淆，还是*先*做协变混淆升维、*再*在外面套一层动态噪声？

一句话答案

这是个伪二选一。数学上这两条路生成的是*同一个*噪声族，顺序本身不是自由度。真正只有一个选择：噪声落在「盲区」里（免费、精确、但隐私值零），还是落在盲区外面（等于直接给明文加噪、要付精度、汇率极差）。你倾向的「先加噪再混淆」等于前者，在*正确性*上确实是唯一可行的选择——但它不能被当成隐私来源。

怎么读

绿色框是大白话，蓝色框是严格推导，灰色框是数值核验。只想知道结论就读绿色框和第 8 节。

本文所有代数命题都在 FP64 下跑过数值核验，随机种子 `20260919`。核验脚本、原始记录路径与复现命令见附录 A。

目录

1 先把问题摆清楚 **2**

1.1 我们现在在做的事 2

1.2 两个候选方案 3

2 发现一：这其实不是两个方案 **3**

3 发现二：噪声只有两种，一种免费一种要钱 **4**

3.1 「盲区」是什么 4

3.2 盲区有多大，而且已经被填满了 4

4 发现三：免费的那种，隐私值零 **5**

4.1 那「M 保密」值多少钱 5

5 发现四：但免费的那种，是唯一保得住正确性的 **6**

6 发现五：要钱的那种，汇率很差 **7**
6.1 真正的壁垒：信噪比，不是放大 7

7 发现六：LWE 的「难」不在噪声，在取模 **8**

8 所以应该怎么做 **9**
8.1 对你那个具体问题的回答 9
8.2 真正该做的：删掉「顺序」，改成「双通道预算」 9
8.3 项目口径 10
8.4 一个代价可能为零的方向 10

9 一个能马上否证本文的实验 **10**

10 核验记录一览 **11**

11 不能声称的内容 **11**

A 复现命令 **11**

B 符号表 **12**

1 先把问题摆清楚

1.1 我们现在在做的事

大白话

把模型某一层的隐藏状态 h 想成空间里的一个点。明文推理时，服务器直接看到这个点的坐标。我们的做法是给它**换一套坐标架**：

(1) **升维**：先用一个保密矩阵 $\hat{P}$ 把 d 维的 h 抬到更高的 D 维（这是 AloePri 那套）；
(2) **拼噪声**：再在后面拼一小段 r 维的辅助噪声 e；
(3) **混合**：整体乘一个保密可逆矩阵 M，得到服务器看到的 c。

服务器看到的 c 是「同一个点在另一套坐标架下的读数」。因为 M 可逆，线性层可以整体换算，算出来的信号和明文**一模一样**。这就是「协变」。

严格版

行向量约定。$h \in \mathbb{R}^d$, $\hat{P} \in \mathbb{R}^{d\times D}$ 且有右逆 $\hat{Q}$ 满足 $\hat{P}\hat{Q} = I_d$, $e \in \mathbb{R}^r$, $N = D+r$, $M \in \mathbb{R}^{N\times N}$ 可逆。

$$c = [\,h\hat{P},\ e\,]\,M, \tag{1}$$

$$L = M^{-1}\begin{bmatrix}\hat{Q}\\ 0\end{bmatrix} \in \mathbb{R}^{N\times d}, \qquad cL = h. \tag{2}$$

L 叫**语义读取矩阵**。$B_c \in \mathbb{R}^{(D-d)\times D}$ 是补空间噪声基，满足 $B_c\hat{Q} = 0$。

1.2 两个候选方案

两条路线

方案 A（先加噪，再混淆）：噪声作为拼进去的那几个坐标，在乘 M 之前就已经在里面了。

$$c_A = [h\hat{P} + aB_c,\ e]M$$

方案 B（先混淆，再外面加动态噪声）：先按老办法算出 c，然后在 c 上直接加一个随机向量 n。

$$c_B = [h\hat{P},\ e]M + n$$

直觉上 A 更「像 LWE 的增广矩阵」，B 更「像在密文上加噪」。下面会看到，这个直觉需要修正。

2 发现一：这其实不是两个方案

大白话

在外面加的噪声，等于在里面加的噪声。

因为 M 可逆，你在外面加的任何一个 n，都可以「倒推」回去：它相当于在乘 M 之前就加了 nM^{-1}。反过来也一样。所以「先后顺序」根本没有创造新东西——A 和 B 是同一个集合的两种参数化。

用信封打比方：你可以在装进信封之前往信纸上涂点东西，也可以在封好之后往信封外面涂点东西。因为信封的封装规则（M）是已知且可逆的，这两种涂法能达到的所有效果是同一批，只不过「外面涂的图案」换算成「里面涂的图案」时要过一道换算。

定理 1：共轭等价

令 $\delta = nM^{-1} = [\delta_x, \delta_e]$，则

$$c_B = [h\hat{P},\ e]M + n = \big([h\hat{P},\ e] + nM^{-1}\big)M = [h\hat{P} + \delta_x,\ e + \delta_e]M.$$

M 可逆 $\Rightarrow$ $n \mapsto nM^{-1}$ 是 $\mathbb{R}^N$ 上的双射 $\Rightarrow$ 两个方案张成的可见状态集合完全相同。□

核验记录

相对误差 1.57×10^{-15}（FP64 舍入级）。

这一条把问题改写了

既然顺序不是自由度，那唯一剩下的问题是：δ_x**（也就是噪声对语义那部分的影响）落在哪里？**后面全部围绕这一点。

3 发现二：噪声只有两种，一种免费一种要钱

3.1 「盲区」是什么

大白话

解码就是拿 c 乘一下 L。既然是矩阵乘法，就必然有一批方向乘完等于零——往这些方向推多远，解码结果都一点不变。这批方向就是 L 的核，记作 $\ker L$，我们叫它**盲区**。
于是噪声只有两类：

- **盲区内**：解码器完全看不见它。信号一点不受影响，免费。
- **盲区外**：解码出来的东西就是「真信号 + 一个误差」。这个误差就是精度损失，要付钱。

而且付多少钱是可以精确算出来的，没有任何「被混淆矩阵打散、难以追踪」的模糊空间。

定理 2：语义误差恒等式

$$\boxed{\mathrm{Dec}(c+n)-h=(c+n)L-h=nL}$$

外加噪声 n 对语义的全部影响就是 $\delta_h := nL$，精确线性。□

核验记录

相对误差 3.78×10^{-15}。$\|n\|=4.12$ 时 $\|\delta_h\|=1.75$。

3.2 盲区有多大，而且已经被填满了

大白话

盲区的大小刚好是 $(D-d)+r$：

- 那个 r 是拼进去的噪声维度；
- 那个 $D-d$ 是**升维白送的**。

这就把「升维到底有什么用」讲清楚了：**升维唯一的数学作用，就是把免费噪声的额度从 r 扩大到 $(D-d)+r$。**
更关键的是：仓库里已有的 `expanded_full` 方案（补空间噪声 a 加拼接噪声 e）**恰好就是整个盲区**，不多不少。所以——
在保住精确性的前提下，「再在外面加一层动态噪声」严格地加不进任何东西。免费额度已经用完了。你要么落回盲区里（只是换了个写法），要么落到盲区外（开始付精度）。

定理 3：免费噪声锥的饱和

$$\ker L=\left\{[aB_c,\ e]M\ :\ a\in\mathbb{R}^{D-d},\ e\in\mathbb{R}^r\right\}$$

证明. $\mathrm{rank}\,L=\mathrm{rank}\,\hat{Q}=d$，故 $\dim\ker L=N-d=(D-d)+r$。另一方面

$$[aB_c,e]M\cdot M^{-1}\begin{bmatrix}\hat{Q}\\0\end{bmatrix}=[aB_c,e]\begin{bmatrix}\hat{Q}\\0\end{bmatrix}=aB_c\hat{Q}=0,$$

故右侧 $\subseteq\ker L$；M 可逆且 B_c 满行秩，右侧维数正是 $(D-d)+r$。包含关系加维数相等，

得相等。□

核验记录

d=32, D=48, r=8：$\dim\ker L = 24 = (48-32)+8$，与 `expanded_full` 噪声空间的最大主角 3.3×10^{-8} rad（即 $1-\cos\approx 5\times10^{-16}$，FP64 舍入级），两组基通过 L 的最大泄漏分别为 1.6×10^{-16} 与 6.7×10^{-16}。两个子空间数值上相同。

4 发现三：免费的那种，隐私值零

大白话

坏消息来了。$c=[h,e]M$ 是一个可逆变换。可逆意味着：h 是被**无损**编码在 c 里的。只要知道 M，h 就是 c 的一个确定性函数，跟噪声加了多大、怎么刷新、用什么密钥派生，一点关系都没有。

我们把盲区噪声放大到一万亿倍（10^{12}）测过：h 的恢复误差仍然只有 6.7×10^{-4}，而且这个残差是浮点舍入造成的，不是噪声遮蔽造成的。

也就是说：**方案 A 的机密性 100% 压在「M 保密」上，噪声一分钱不出**。这正是「再多花点算力就能破」这个感觉的数学根源——而实际情况比「更多算力」还要糟，因为它是闭式的。

定理 4：零条件熵

给定 M，由式 (2)，$h=c_AL$ 是 c_A 的确定性函数，与 a,e 的分布和幅度无关。故

$$H(h\mid c_A,M)=0,\qquad I(h;c_A\mid M)=H(h).$$

核验记录

盲区噪声尺度 $10^0/10^6/10^{12}$，h 恢复相对误差 $1.8\times10^{-15}/1.1\times10^{-9}/6.7\times10^{-4}$。与仓库 `PROBLEMS.md` §1.5 记录的 5.7×10^{-4} 一致。

4.1 那「M 保密」值多少钱

大白话

基座模型是公开的（Llama、DeepSeek、Qwen 都开源），所以攻击者可以自己跑明文模型，拿到任意输入对应的真 h。手上有若干组「真 h + 看到的 c」之后，恢复解码器**不需要搜索，也不需要训练**，一次 SVD 加一次最小二乘就出来了。

需要多少组？大约等于环境维度加一。把盲区填满（`expanded_full`）能把这个数从 $d+r+1$ 抬到 $N+1$——这就是填满盲区的全部安全收益，一个加性常数。

代入真实规模 $d=4096$、$N\approx4112$：约 4113 条样本，7×10^{10} 次浮点运算，单张卡亚秒级。

已知明文闭式恢复

写 $c_t=h_tA+\nu_tB$，$A=\hat{P}M_x$，ν 为全部辅助自由度，$\rho:=\operatorname{rank}B$。

1. $P_H^{\perp}=I_T-QQ^{\top}$，$Q$ 为 H 的正交基；

2. $P_H^{\perp} C = P_H^{\perp} N B$ 秩 $\le \rho$，取其右零空间 V，$\dim V = N - \rho = \dim \ker B$；
3. 对 $v \in \ker B$ 有 $c_t v = h_t(Av)$，最小二乘得 AV；
4. 解码器 $\hat{L} = V(AV)^{+}$，满足 $c\hat{L} = h$。

样本需求 $T^{*} = d + \rho + 1$，准备代价 $O(TN^2)$，逐目标解码 $O(Nd)$。

核验记录

方案	辅助秩 ρ	所需样本	留出集恢复相对误差
`expanded_concat`	8	T=39 失败，T=41 成功	5.1×10^{-15}
`expanded_full`	24	T=55 失败，T=57=N+1 成功	5.7×10^{-15}

附注：`concat` 下恢复的 $\hat{L} \neq L$（矩阵相对差 0.33），但在可达状态集上逐点相等；`full` 下可达集满维，故 $\hat{L} = L$ 精确恢复。换句话说，填满盲区反而让攻击者拿到的是真解码器本身。

5 发现四：但免费的那种，是唯一保得住正确性的

大白话

Transformer 里不全是矩阵乘法。RMSNorm、Softmax、SiLU、Top-k 这些非线性运算不认识换坐标这回事。

盲区噪声能过这些关卡，因为解码器根本看不见它——喂给非线性层的东西一点没变。

盲区外的噪声过不去。要让它过去，需要存在一个与 h 无关的矩阵，把「非线性前加的扰动」翻译成「非线性后加的扰动」（只有这样才能离线吸收进权重）。这样的矩阵不存在，因为 RMSNorm 的雅可比矩阵本身就依赖 h。我们拿 4000 组样本去最优拟合这个矩阵，不可约残差 21.7%，而且在两个不同的扰动尺度下都是 21.7%——说明这不是「高阶项太小」的问题，是结构性的不可能。

这是你的直觉真正成立的地方，而且是决定性的：盲区噪声与所有非线性检查点严格交换，盲区外的噪声结构性地做不到。所以方案 A 是唯一能保住 exact 模式、能把变换离线吸收进权重、能守住 5% 开销目标的选择。

定理 5：非线性检查点的不可交换性

exact 协变要求存在与 h 无关的 Φ 使 $F(h+\delta) = F(h) + \delta\Phi$。对 $F = \mathrm{RMSNorm}$，

$$\frac{\partial F}{\partial h} = \frac{1}{\rho(h)}\Big(I - \frac{hh^{\top}}{d\,\rho(h)^2}\Big), \qquad \rho(h) = \sqrt{\tfrac{1}{d}\|h\|^2 + \epsilon},$$

显含 h，故无此 Φ。反之 $n \in \ker L$ 时 $F\big((c+n)L\big) = F(cL) = F(h)$。□

核验记录

h 变化时最优 Φ 的不可约相对残差：扰动尺度 10^{-1} 下 21.86%，10^{-3} 下 21.66%。对照：范数 279 的盲区噪声通过检查点后误差 1.2×10^{-14}。

6 发现五：要钱的那种，汇率很差

大白话

方案 B 确实买到了真东西——这是方案 A 完全没有的：每条样本都有一个消不掉的误差下限。就算攻击者知道全部密钥，他解出来的也只是「真值 + 你注入的那个误差」。

但账要算清楚：

- **密钥还是会泄漏**，而且是以 $1/\sqrt{T}$ 的速度。攻击者攒 T 条样本做最小二乘，误差就按 $1/\sqrt{T}$ 缩小。噪声只是让他多攒点样本，不是让他做不到。
- **每条样本的误差下限严格线性于你注入的量**。注入 10^{-4}，下限就是 0.64×10^{-4}。没有任何放大效应帮你。
- **动态刷新不防重复观测**。同一个 token 被看 T 次、每次新鲜噪声，攻击者取个平均就把噪声压到 $1/\sqrt{T}$。看 100 次，就抹掉一个数量级。

核验记录

$\sigma_n = 0.05$ 时密钥恢复：$T = 256/1024/4096/16384$ 对应相对误差 0.177/0.090/0.049/0.023，乘 $\sqrt{T}$ 后恒为 2.8∼3.1，确认 $T^{-1/2}$ 速率。

误差下限线性性：$\sigma_n = 10^{-4}/10^{-3}/10^{-2}/10^{-1}$ 时，解码相对误差除以 σ_n 恒为 0.64。盲区噪声对照：1.4×10^{-15}（无下限）。

6.1 真正的壁垒：信噪比，不是放大

大白话

很多人以为问题是「噪声会在 28 层里被放大」。我实测了，不是这样：

- 纯线性部署链 28 层，相对误差基本不变（末/首 = 0.52，甚至略降）；
- 加上非线性栈（RMSNorm + softmax 注意力 + SwiGLU）28 层，放大约 2.5×。

放大系数只有个位数。**真正的壁垒是信噪比本身**：要让泄漏降到「每个坐标只剩 1 bit」，你注入的噪声必须达到信号的 58%。那时模型输出已经是噪声了。就算放大系数等于 1，这道墙也在。

反过来看我们现在的操作点：$\tau = 10^{-5}$ 时每个坐标还留着 16.6 bit，基本等于完整状态——可是已经付了 2×10^{-3} 的 logit 误差。这就是汇率差的意思。

信噪比壁垒

高斯信道 $h \mapsto h + \delta_h$：

$$\text{每坐标保留信息} = \tfrac{1}{2}\log_2\!\left(1 + \frac{\sigma_h^2}{\sigma_\delta^2}\right)\ \text{bit}, \qquad \text{输出相对误差} \approx \Lambda \cdot \frac{\sigma_\delta}{\sigma_h}.$$

表 1: 信噪比壁垒：要真正藏住信息，噪声必须和信号同量级

σ_δ/σ_h	每坐标保留 bit	备注
10^{-5}	16.6	当前操作点附近，等于没藏
10^{-3}	10.0	
10^{-2}	6.6	
10^{-1}	3.3	
0.577	1.0	模型已报废（58% 相对误差）
1.0	0.5	

这是 ℓ_2 几何的硬约束

换矩阵结构、调条件数、加大 r、改刷新策略，都绕不过这张表。因为它只用到「信号和噪声在同一个实数向量空间里」这一个事实。

7 发现六：LWE 的「难」不在噪声，在取模

大白话

这一条直接回答「LWE 的增广矩阵加噪」。

标准 LWE 是 $b = As + e \bmod q$。它之所以难，**是因为那个 $\bmod q$ 的回绕，不是因为加了噪声**。同一个秘密、同一批噪声，换个代数环，难度天差地别：

- 实数域上：64 条样本，最小二乘取整后，秘密矩阵 100% 的条目完全正确；
- $\mathbb{Z}_q$ 上：同样的估计量，64 到 4096 条样本，正确条目比例恒为 0%。

而浮点 GEMM 管线里没有 $\bmod q$。所以：

「先做 LWE 增广矩阵加噪」里的「LWE」只是命名，不是机制。我们放在盲区里的 e、ξ，无论用 ML-KEM 建密钥还是 SHAKE256 派生，代数上都只是实数域上盲区里的一个元素，被 L 一次矩阵乘法精确消掉。

要真正拿到 LWE 的困难性，必须把代数结构换到 $\mathbb{Z}_q$。而那和「≤ 5% 开销」「exact 模式」「TensorCore 浮点 GEMM」三条同时冲突。这是个需要项目层面决策的取舍，不是能在现有构造里打补丁解决的。

核验记录

$q = 3329$（ML-KEM 模数，仅作代表性小素数），$\sigma = 2$，$d = n = 16$。

	$T = 64$	$T = 1024$	$T = 4096$
实数域，$\|\hat{M} - M\|$ 相对误差	1.6×10^{-7}	3.4×10^{-8}	1.6×10^{-8}
实数域，取整后完全正确条目	100%	100%	100%
$\mathbb{Z}_q$，相对误差	≈ 1.0	≈ 1.0	≈ 1.0
$\mathbb{Z}_q$，取整后完全正确条目	0%	0%	0%

这是「估计量失效」的演示，不是困难性证明；真正的 LWE 困难性建立在格归约上。

8 所以应该怎么做

8.1 对你那个具体问题的回答

大白话

选 A（先加噪再混淆）。但理由要换成正确的那一个。
不是因为「更符合直觉」或「更像 LWE」，而是因为：

盲区是唯一与非线性检查点严格交换的噪声子空间（发现四），
因此是唯一能离线吸收进权重、保住 *exact* 合同、保住 *5%* 开销的选择。

同时必须如实登记：**它的隐私贡献上界是零（发现三）。**
而 B 不是一个「另一种机制」，它只是 A 再叠一个明文级扰动。把它当成「在密文外面加噪，像 LWE 那样」来理解，会导致高估它的安全收益、低估它的精度代价。

8.2 真正该做的：删掉「顺序」，改成「双通道预算」

大白话

把整个空间按「盲区 ⊕ 语义」劈成两个通道，分别记账、分别定预算。这样每一分噪声花在哪、买到了什么、付了多少精度，全都可审计。

表 2: 双通道噪声预算

	通道 0：盲区内	**通道 1：语义方向**
维数	$(D-d)+r$，已由 `expanded_full` 打满	d
正确性代价	0（精确）	$\Lambda \cdot \sigma_\delta/\sigma_h$，$\Lambda \approx 2.5$
信息论隐藏	**0**	唯一来源
安全收益	把已知明文样本需求从 $d{+}r{+}1$ 抬到 $N{+}1$；打掉「token → 固定向量」字典	每样本误差下限 $\|\delta_h\|$
该放在哪	离线吸收进权重，逐请求刷新	**非线性检查点、语义基底内**，用 Δ_k / D_V / ρ 定价

通道 1 的关键工程判断

如果要加语义噪声，就在语义基底的检查点里加，不要在混合坐标外面加。
两者由定理 1 严格等价，但只有在语义基底里你才有可定价的误差界（$\|q-p\|_1 \le \tau$、$D_{KL} \le \tau^2/2$、$\|(q-p)V\|_2 \le \frac{D_V}{2}\tau$，见 `DERIVATION_PACKAGE.md` §5）。在混合坐标外面加，等于把同一个噪声搬到一个你写不出误差界的坐标系里，还顺手污染了噪声链。

这才是「顺序」唯一真正有内容的版本：相对非线性检查点的位置，而不是相对 M 的位置。

8.3 项目口径

大白话

「目标不是绝对安全」是对的，而且是这个方案唯一站得住的定位。但要变成可验收的东西，口径必须是 `work_factor_security.md` 那一套：**最小攻击成本曲线，而且由最便宜的那条攻击决定**。

按本文推导，当前最便宜的三条是：

1. $\rho = \mathrm{rms}(h) \to$ 公开 embedding 行范数查表 $\to$ token。已实测 92∼93%，最便宜。
2. 已知明文闭式解码器恢复。$T^* = N + 1$，$O(TN^2)$，无搜索无训练。（本文新增核验）
3. 重复观测取平均，$\sigma_\delta/\sqrt{T}$。

增大 r、增大 D、加大条件数、换刷新策略，对这三条都没有量级影响。

这一点必须和答辩 PPT 里「离线模型混淆」那一页一起讲清楚：我们真正的卖点是「在 $\leq 5\%$ 开销下把最便宜攻击的成本抬高 G 倍，并且有实测曲线」，不是「数据被保护了」。

8.4 一个代价可能为零的方向

大白话

目前通道 1 的预算几乎全花在扰动 ρ 上。但 ρ 泄漏的根源是「公开 embedding 的行范数几乎两两不同」——这是**基座模型的属性**，不是混淆构造的属性。

如果离线把 embedding 做等范数化，把各行的范数差异吸收进第一层投影，第 0 层这条最便宜的通道可能以接近零精度代价关掉。

这比继续往盲区里加噪的期望收益高得多——后者已被发现二、三证明为零。

9 一个能马上否证本文的实验

大白话

按发现五的账，$\tau = 10^{-5}$ 时每坐标仍保留 16.6 bit；而我们实测 token 恢复率从 93.8% 掉到 3.9%。这两件事同时成立只有一个解释：

掉的是那条查表攻击的脆弱性，不是信息量。

预测：把「唯一匹配」换成「τ 邻域候选集 + 语言模型重排」，或者对同一 token 的多次观测取平均，在 $\tau = 10^{-5}$ 下 token 恢复率应显著高于 3.9%。

这个实验能直接否证本文整套论证，也正好补上 `problem_analysis.md` §5.3 的证据缺口。建议排在补测 PPL / MMLU 之前，因为它便宜，而且它的结果决定了要不要继续在 $\tau = 10^{-5}$ 这个操作点上花精度预算：

- 跑不出来 $\Rightarrow$ 本文的信息论记账在这个具体攻击面上过于悲观；
- 跑出来了 $\Rightarrow$ $\tau = 10^{-5}$ 不能作为隐私结论使用。

10 核验记录一览

编号	命题	结果
T1	顺序等价（共轭）	rel err 1.57×10^{-15}
T2	语义误差 $= nL$	rel err 3.78×10^{-15}
T3	$\dim\ker L = (D-d)+r$，且 = `expanded_full` 噪声空间	子空间数值相同
T4	盲区噪声 $\times 10^{12}$ 仍可无损恢复 h	rel err 6.7×10^{-4}
T5	已知明文闭式解码器恢复	T^*=41 / 57，rel err $\sim 5 \times 10^{-15}$
T6	外加噪声：密钥仍以 $T^{-1/2}$ 泄漏；误差下限线性	$\times\sqrt{T}$ 恒定；斜率 0.64
T7	非线性检查点无 h 无关的 Φ	不可约残差 21.7%
T8a	纯线性链不放大相对误差	末/首 = 0.52
T8b	非线性栈放大（随机权重代理）	2.5× @ 28 层
T9	信噪比壁垒	1 bit 需 $\sigma_\delta/\sigma_h = 0.577$
T10	困难性来自取模而非噪声	实数 100% vs $\mathbb{Z}_q$ 0%

11 不能声称的内容

边界

- 本文所有数值跑在小随机实例上（d=32, D=48, r=8）。定理 1–5、7 是代数恒等式，与规模无关；**但 T8b 的 $\Lambda \approx 2.5$ 是随机权重代理，不是 Qwen2 / Llama 实测，不能当真实放大系数引用**。
- T10 演示的是最小二乘估计量失效，**不是** LWE 困难性证明。
- 全部结论限于诚实但好奇的观察者。可修改 kernel、dump 寄存器、读取全部客户端秘密的云端**不在保护范围内**。
- 不声称 IND-CPA、信息论不可恢复、差分隐私、全同态、端到端加密，或任何密码学安全位数。
- 不声称任何没有 recorded run 支撑的精度、延迟或隐私数字。

允许的措辞：增广协变混淆、链式辅助噪声、有界 logit 扰动、近似隐私保护推理原型、exact 模式 / approximate 模式，以及「在已评测攻击集合与恢复目标下的观测攻击工作因子」。

A 复现命令

```
cd /Users/yin/code/fastProve

# 本文全部数值核验（T1--T10，FP64，种子 20260919）
python docs/verification/verify_noise_ordering.py \
```

```
    --output results/raw/noise_ordering_analysis_20260919.json

# 编译本文档
xelatex docs/noise_placement_explained.tex   # 跑两遍以生成目录
```

B 符号表

符号	含义
$h \in \mathbb{R}^d$	语义隐藏状态（要保护的东西）
$\hat{P} \in \mathbb{R}^{d\times D}$，$\hat{Q} \in \mathbb{R}^{D\times d}$	升维映射与其右逆，$\hat{P}\hat{Q} = I_d$
$e \in \mathbb{R}^r$	拼接的辅助噪声
$a \in \mathbb{R}^{D-d}$	补空间噪声
$B_c \in \mathbb{R}^{(D-d)\times D}$	补空间噪声基，$B_c\hat{Q} = 0$
$M \in \mathbb{R}^{N\times N}$，$N = D + r$	保密可逆混合矩阵
$c \in \mathbb{R}^N$	服务器可见的混合状态
$L = M^{-1}[\hat{Q}; 0]$	语义读取矩阵，$cL = h$
$\ker L$	「盲区」：$\{n : nL = 0\}$，维数 $(D-d)+r$
n	外加噪声
$\delta_h = nL$	外加噪声造成的语义误差
Λ	语义扰动经网络到输出的放大系数
τ	扰动无穷范数上界
T	攻击者持有的样本数
$\rho(h)$	RMSNorm 的归一化因子