

OSNIP vs fastProve：精度损失对照表

聚焦 Llama-3.2-3B-Instruct

fastProve evaluation

August 2, 2026

说明：左列取自 OSNIP 论文(Cao et al., Tables 1–3); 右列取自本仓库大规模实测 results/raw/llama_compare_large.json (1500 条真实场景 prompt × 3 master keys, BF16, RTX 5090)。两侧指标定义不同，已分行写清，避免混读。

对比项	OSNIP (论文)	fastProve (本工作)
方案定位	客户端 embedding 混淆语义零空间注入	全层增广状态协变混淆 (structural / full)
同模型	Llama-3.2-3B-Instruct	Llama-3.2-3B-Instruct
主要精度定义	相对非私有基线的 任务准确率保留	相对明文路径的 轨迹一致率
任务平均保留 RP	98.49% (10 项任务 Avg Acc: 0.597 → 0.588)	structural 100.1% full 97.46% (同 10 项 $n=200$, osnip_style_bench_n200.json)
MMLU (3B)	0.606 → 0.572 (约 -3.4 pp)	plain 0.295 / struct 0.295 / full 0.315 ($n=200$ 子集，绝对分协议不同)
与明文 token 一致率	— (论文不以此为主指标)	structural 96.26% full 89.39% (3 keys 平均)
生成整段一致	摘要 BERTScore RP $\approx$ 100% (相对非私有任务分，非轨迹对齐)	structural 84.51% full 63.13% (与明文 greedy 后缀 exact match)
PPL 相对增幅 $\Delta\%$	WikiText-2: +31% (9.63 → 12.58)	structural $\approx$ 0% full +5.79% (1500 prompts 上 mean)
同论文其他基线 (3B PPL)	Cape +913%, DynText +1066%, InferDPT +29699%	远低于上述量级
数据规模 (精度侧)	标准基准 + WikiText-2 + 1000 摘要样本等	1500 真实场景 prompt × 3 keys

对照结论

- PPL**：在 Llama-3.2-3B 上，fastProve (struct. $\approx$ 0%, full +5.8%) 的困惑度膨胀**小于** OSNIP 论文的 +31%。
- 任务准确率**：OSNIP 给出近无损任务 RP (98.5%); fastProve **尚无**同协议任务榜，不能据此声称全面更优。

3. **轨迹对齐**: 仅 fastProve 直接报告与明文 token/greedy 一致率 (struct. $\sim 96\%/85\%$; full $\sim 89\%/63\%$)。

来源: OSNIP Tables 1-3 (Llama-3.2-3B-Instruct); fastProve llama_compare_large.json (3 keys 平均)。