

OSNIP 同协议任务精度：论文 vs fastProve

Llama-3.2-3B-Instruct

fastProve evaluation

August 2, 2026

说明：左列取自 OSNIP 论文 Table 1 / Table 2 (Llama-3.2-3B-Instruct)；右列为本仓库当前协变混淆方案在 RTX 5090 上实测 (results/raw/osnip_style_bench_n200.json, 每任务 $n=200$, 1 master key)。评分：闭集任务为 continuation 对数似然 MC；WikiText-2 为滑动窗口 teacher-forced PPL。绝对分受 prompt / chat 模板 / 子集影响，不可与论文硬对齐；相对保留率 RP 与 PPL 相对增幅才是公平主指标。

闭集准确率与 RP

任务	OSNIP 明文	OSNIP	OSNIP RP	fastProve 明文	structural	full
ARC-E	0.712	0.707	99.3%	0.535	0.530	0.505
PIQA	0.768	0.766	99.7%	0.460	0.460	0.460
MNLI	0.542	0.535	98.7%	0.480	0.485	0.495
SST-2	0.867	0.825	95.2%	0.970	0.965	0.950
ANLI-R1	0.440	0.431	98.0%	0.475	0.480	0.415
ANLI-R2	0.401	0.407	101.5%	0.395	0.400	0.355
ANLI-R3	0.425	0.410	96.5%	0.350	0.350	0.350
WiC	0.497	0.513	103.2%	0.505	0.505	0.505
HellaSwag	0.716	0.709	99.0%	0.465	0.465	0.455
MMLU	0.606	0.572	94.4%	0.295	0.295	0.315
闭集平均	0.597	0.588	98.49%	0.493	0.494	0.481
RP (相对各自明文)	100%	98.49%	—	100%	100.1%	97.46%

WikiText-2 困惑度

指标	OSNIP 明文 → 混淆	fastProve structural	fastProve full
PPL	9.63 → 12.58	11.59 → 11.61	11.59 → 11.73
相对增幅 $\Delta\%$	+31%	+0.12%	+1.15%

结论

- 任务保留率：structural 在 10 项闭集上相对明文 RP $\approx 100\%$ ；full RP $\approx 97.5\%$ ，与 OSNIP 论文 98.5% 同量级。
- PPL：structural +0.12%、full +1.15%，远低于 OSNIP 报告的 +31%（绝对 PPL 因窗口不同不可硬比）。
- 绝对分：本协议未使用 chat template，若干任务（PIQA / HellaSwag / MMLU）绝对准确率低于论文非私有基线；这不改变“混淆相对明文”的保留率结论。
- 未测：隐私 KNN-ASR、CNN/DM 摘要 ROUGE/BERTScore（OSNIP Table 3）。

来源：OSNIP Tables 1–2；fastProve osnip_style_bench_n200.json ($n=200$ /任务, BF16, RTX 5090, current covariant scheme)。